

PROJET

Probabilités & Statistiques

Analyse Statistique et Modélisation Probabiliste de la Fraude dans les Assurances Automobiles

Domaine	Statistiques & Probabilités
Type de données	Variables discrètes et continues
Méthode principale	Régression Logistique
Source des données	Dataset assurances automobiles (15 420 obs.)
Langage	Python (pandas, numpy, matplotlib, sklearn)

Étudiants : BLAGNA Abdoul Kader
COULIBALY Lessi Elvis Stanislas
BAGAYA Seydou

Professeur : Dr TRAORE

2025 – 2026

I. Résumé

La détection de la fraude dans les assurances constitue un enjeu économique majeur. Ce projet propose une approche statistique et probabiliste rigoureuse pour modéliser et prédire les comportements frauduleux à partir de données réelles issues de contrats d'assurance automobile.

En combinant l'analyse de variables aléatoires discrètes (*FraudFound*, *Fault*) et continues (*VehiclePrice*), nous construisons un modèle de régression logistique permettant de distinguer les sinistres frauduleux des sinistres légitimes sur un jeu de 15 420 observations.

Problématique : *Quelles variables influencent significativement la probabilité de fraude dans un sinistre automobile, et peut-on construire un modèle prédictif fiable à partir de ces données ?*

Méthode de résolution : Analyse descriptive univariée → modélisation probabiliste par lois de Bernoulli et mélange de lois Normales → analyse des corrélations → régression logistique supervisée.

Finalité : Ce travail vise à fournir un outil d'aide à la décision pour les équipes anti-fraude des compagnies d'assurance, en automatisant le signalement des dossiers suspects.

II. Introduction

0. Contexte et accroche

La fraude à l'assurance automobile représente des milliards d'euros de pertes annuelles pour les compagnies d'assurance à travers le monde. Selon plusieurs études sectorielles, entre 5 % et 15 % des sinistres déclarés contiendraient une part de fraude, qu'elle soit totale ou partielle. Cette réalité impose aux assureurs de développer des mécanismes robustes de détection ([Aslam et al., 2022](#); [Debener et al., 2023](#)). Dans ce contexte, l'exploitation des données historiques de sinistres constitue une approche particulièrement prometteuse.

Notre dataset, chargé depuis un dépôt GitHub, comprend 15 420 observations et des variables décrivant l'assuré, l'accident et la réclamation. Le taux de fraude observé est de 6 %, ce qui en fait un problème de classification déséquilibré — un défi classique en apprentissage statistique.

0. Méthodes précédemment utilisées et leurs limites

Plusieurs approches ont été utilisées dans la littérature pour traiter ce type de problème :

- **Règles expertes** (systèmes à base de règles) : simples à interpréter mais rigides, elles ne s'adaptent pas aux nouvelles formes de fraude et nécessitent une maintenance manuelle constante.

- **Arbres de décision** : interprétables mais sujets au surapprentissage, et peu robustes face aux données déséquilibrées comme celles rencontrées ici (94 % de non-fraude).
- **Régression logistique** ([Artís et al., 2002](#)) : méthode statistiquement fondée, interprétable et adaptée aux variables binaires. Elle constitue notre approche principale, justifiée par la nature de la variable cible (*FraudFound* : Oui/Non) et la faible dimensionnalité après sélection des variables pertinentes.

0. Objectif du projet

L'objectif est double : (1) caractériser statistiquement les variables liées à la fraude et (2) construire un modèle prédictif permettant de scorer automatiquement un nouveau sinistre. Ce travail peut servir aux équipes anti-fraude pour prioriser les dossiers à instruire manuellement.

III. Matériels et Méthodes

1. Données

Le jeu de données provient d'un dépôt GitHub public et contient 15 420 lignes et plusieurs dizaines de colonnes. Pour cette étude, nous avons retenu quatre variables clés après nettoyage (suppression des colonnes *AccidentArea* et *Age*) :

Variable	Type	Description
FraudFound	Discrète (Bernoulli)	Variable cible : fraude détectée (Yes/No)
VehiclePrice	Continue (mélange Normal)	Prix du véhicule (encodé en midpoint)
PastNumberOfClaims	Discrète	Nb de réclamations passées (0, 1, 2-4, >4)
Fault	Discrète (Bernoulli)	Responsabilité : Policy Holder / Third Party

2. Modélisation mathématique

Chaque variable retenue a été associée à une loi de probabilité adaptée à sa nature : **FraudFound** : Variable binaire.

$$FraudFound \sim \mathcal{B}(p), \quad p = 0,06$$

On en déduit : $\mathbb{E}[X] = 0,06$; $\mathbb{V}(X) = p(1 - p) = 0,056$; $\sigma(X) = 0,237$.

Fault : Variable catégorielle binaire.

$$Fault \sim \mathcal{B}(p), \quad p = P(\text{Third Party}) = 0,272$$

$\mathbb{E}[Fault] = 0,272$; $\mathbb{V}(Fault) = 0,272 \times 0,728 \approx 0,198$.

VehiclePrice : Distribution empirique multimodale (5 pics distincts). Modélisée par un mélange de 5 lois normales :

$$VehiclePrice = X_1 + X_2 + X_3 + X_4 + X_5, \quad X_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$$

Statistiques descriptives : moyenne = 28 839 ; médiane = 24 500 ; max = 64 500 ; asymétrie = 0,308.

PastNumberOfClaims : Variable ordinaire encodée (0 = none, 1 = 1, 3 = 2 to 4, 5 = more than 4). Moyenne = 1,95 ; écart-type = 1,70. Suit une distribution discrète non standard.

3. Approche algorithmique et informatique

Le pipeline complet a été implémenté en Python :

- Chargement des données via `pandas` depuis une URL GitHub
- Nettoyage : suppression des colonnes non pertinentes, encodage des variables catégorielles
- Analyse descriptive : `value_counts()`, `describe()`, visualisations avec `matplotlib` et `seaborn`
- Calcul des indicateurs statistiques : moyenne, variance, écart-type, asymétrie (skewness)
- Modélisation : `LogisticRegression` de `sklearn` avec stratification de l'échantillon (150 fraudes, 200 non-fraudes) ([Aslam et al., 2022](#))
- Sauvegarde du modèle avec `joblib` pour une réutilisation sans ré-entraînement

IV. Résultats

1. Analyse descriptive des variables

Le tableau ci-dessous synthétise les indicateurs statistiques calculés pour chaque variable :

Variable	Loi	$\mathbb{E}[X]$	$\mathbb{V}(X)$	$\sigma(X)$
FraudFound	Bernoulli(0,06)	0,060	0,056	0,237
Fault (Third Party)	Bernoulli(0,272)	0,272	0,198	0,445
VehiclePrice	Mélange Normal (×5)	28 839	~78 M	8 850
PastNumberOfClaims	Discrète	1,950	2,887	1,699

2. Interprétation des distributions

FraudFound : 94 % des cas ne sont pas frauduleux (14 497 cas). Seulement 923 cas de fraude détectée (6 %). La moyenne proche de 0 confirme que la fraude est un événement rare dans ce jeu de données.

VehiclePrice : La distribution est multimodale avec des pics distincts autour de 20 000–25 000, 30 000 et 40 000 euros. Elle ne peut pas être modélisée par une seule loi normale ou log-normale. Le coefficient d’asymétrie ($\text{skewness} = 0,308$) indique une légère dissymétrie à droite.

PastNumberOfClaims : La catégorie la plus fréquente est ‘2 to 4’ (5 485 cas). La médiane est de 1 réclamation. Environ 28 % des assurés n’ont aucun antécédent de réclamation.

Fault : 72,8 % des accidents sont imputés au titulaire de la police (*Policy Holder*), contre 27,2 % à un tiers. La probabilité que l’assuré ne soit pas responsable est donc de 27,2 %.

3. Analyse des corrélations avec FraudFound

L’analyse des corrélations linéaires révèle des relations faibles mais interprétables (Debener et al., 2023) :

- *VehiclePrice* ($r = +0,001$) : corrélation quasi nulle. Le prix du véhicule n’est pas discriminant pour détecter la fraude. Variable exclue du modèle prédictif.
- *PastNumberOfClaims* ($r = -0,057$) : très légère corrélation négative. Un plus grand nombre d’antécédents est marginalement associé à moins de fraudes déclarées.
- *Fault* ($r = -0,131$) : corrélation négative la plus forte. Lorsque la faute est attribuée à un tiers, la probabilité de fraude est légèrement supérieure — relation contre-intuitive qui mérite une interprétation contextuelle.

Ces résultats justifient la rétention de *Fault* et *PastNumberOfClaims* comme variables prédictives, en excluant *VehiclePrice*.

4. Modèle de régression logistique

Le modèle a été entraîné sur un échantillon équilibré (150 cas de fraude, 200 cas de non-fraude) avec les variables : *Make*, *AccidentArea*, *Sex*, *MaritalStatus*, *PastNumberOfClaims*, *Fault*, *Deductible*.

Paramètre	Valeur
Taille d’entraînement	350 obs. (75 % train / 25 % test)
Score de test (accuracy)	$\approx 63,6\%$
Bibliothèque	<code>sklearn.linear_model.LogisticRegression</code>
Sauvegarde	<code>joblib (logistic_regression_model.joblib)</code>

5. Discussion des résultats

- **Convergence** : le modèle n'a pas convergé dans la limite d'itérations par défaut (avertissement `lbfgs`). Cela indique que l'espace des paramètres est complexe et que le nombre d'itérations devrait être augmenté (`max_iter=1000` ou plus).
- **Robustesse** : l'échantillon d'entraînement est petit (350 observations) par rapport aux 15 420 disponibles. Le modèle est entraîné sur un sous-ensemble stratifié, ce qui améliore l'équilibre mais réduit la représentativité.
- **Fiabilité** : un score de 63,6 % est modeste. Il reflète la difficulté inhérente à détecter des fraudes rares dans des données déséquilibrées. Des métriques complémentaires (F1-score, ROC-AUC, matrice de confusion) permettraient une évaluation plus fine ([Artís et al., 2002](#)).
- **Ergodicité** : les simulations sur différentes valeurs des 7 features (*Make* encodé de 1 à 7) montrent une prédiction systématique à 0 (non-fraude), ce qui confirme le biais vers la classe majoritaire.

V. Conclusion et Perspectives

0. Synthèse

Ce projet a permis de mettre en œuvre une démarche complète de modélisation statistique et probabiliste appliquée à la fraude dans les assurances automobiles. En partant de données brutes réelles (15 420 sinistres), nous avons caractérisé chaque variable par une loi de probabilité adaptée — Bernoulli pour les variables discrètes binaires, mélange de lois normales pour la variable continue multimodale — et construit un modèle de régression logistique capable de prédire la probabilité de fraude.

Les corrélations calculées montrent que la variable *Fault* (responsabilité de l'accident) est la plus discriminante parmi celles retenues, bien que son effet reste faible. *VehiclePrice* s'avère non pertinente et a été exclue du modèle final.

0. Perspectives

Une perspective naturelle serait d'explorer des méthodes d'apprentissage plus robustes aux données déséquilibrées : Random Forest, Gradient Boosting (XGBoost), ou encore des techniques de rééchantillonnage comme SMOTE (*Synthetic Minority Over-sampling Technique*) ([Debener et al., 2023](#)). L'utilisation de métriques adaptées (AUC-ROC, précision, rappel) permettrait également une évaluation plus fine des performances du modèle.

Code source disponible sur GitHub. Le modèle entraîné est sauvegardé sous le fichier `logistic_regression_model.joblib` pour permettre des prédictions sans ré-entraînement.

V. Bibliographie

V. References

Artís, M., Ayuso, M., et Guillén, M. (2002). Detection of automobile insurance fraud with discrete choice models and misclassified claims. *Journal of Risk and Insurance*, 69(3), 325–340. https://www.researchgate.net/publication/253116638_An_Analytical_Approach_To_Detecting_Insurance_Fraud_Using_Logistic_Regression

Aslam, F., Hunjra, A. I., Ftiti, Z., Louhichi, W., et Shams, T. (2022). Insurance fraud detection: Evidence from artificial intelligence and machine learning. *Research in International Business and Finance*, 62, 101728. Elsevier. <https://www.sciencedirect.com/science/article/abs/pii/S0275531922001325>

Debener, J., Heinke, V., et Weiler, J. (2023). Detecting insurance fraud using supervised and unsupervised machine learning. *Journal of Risk and Insurance*, 90(3), 743–768. Wiley. <https://onlinelibrary.wiley.com/doi/10.1111/jori.12427>